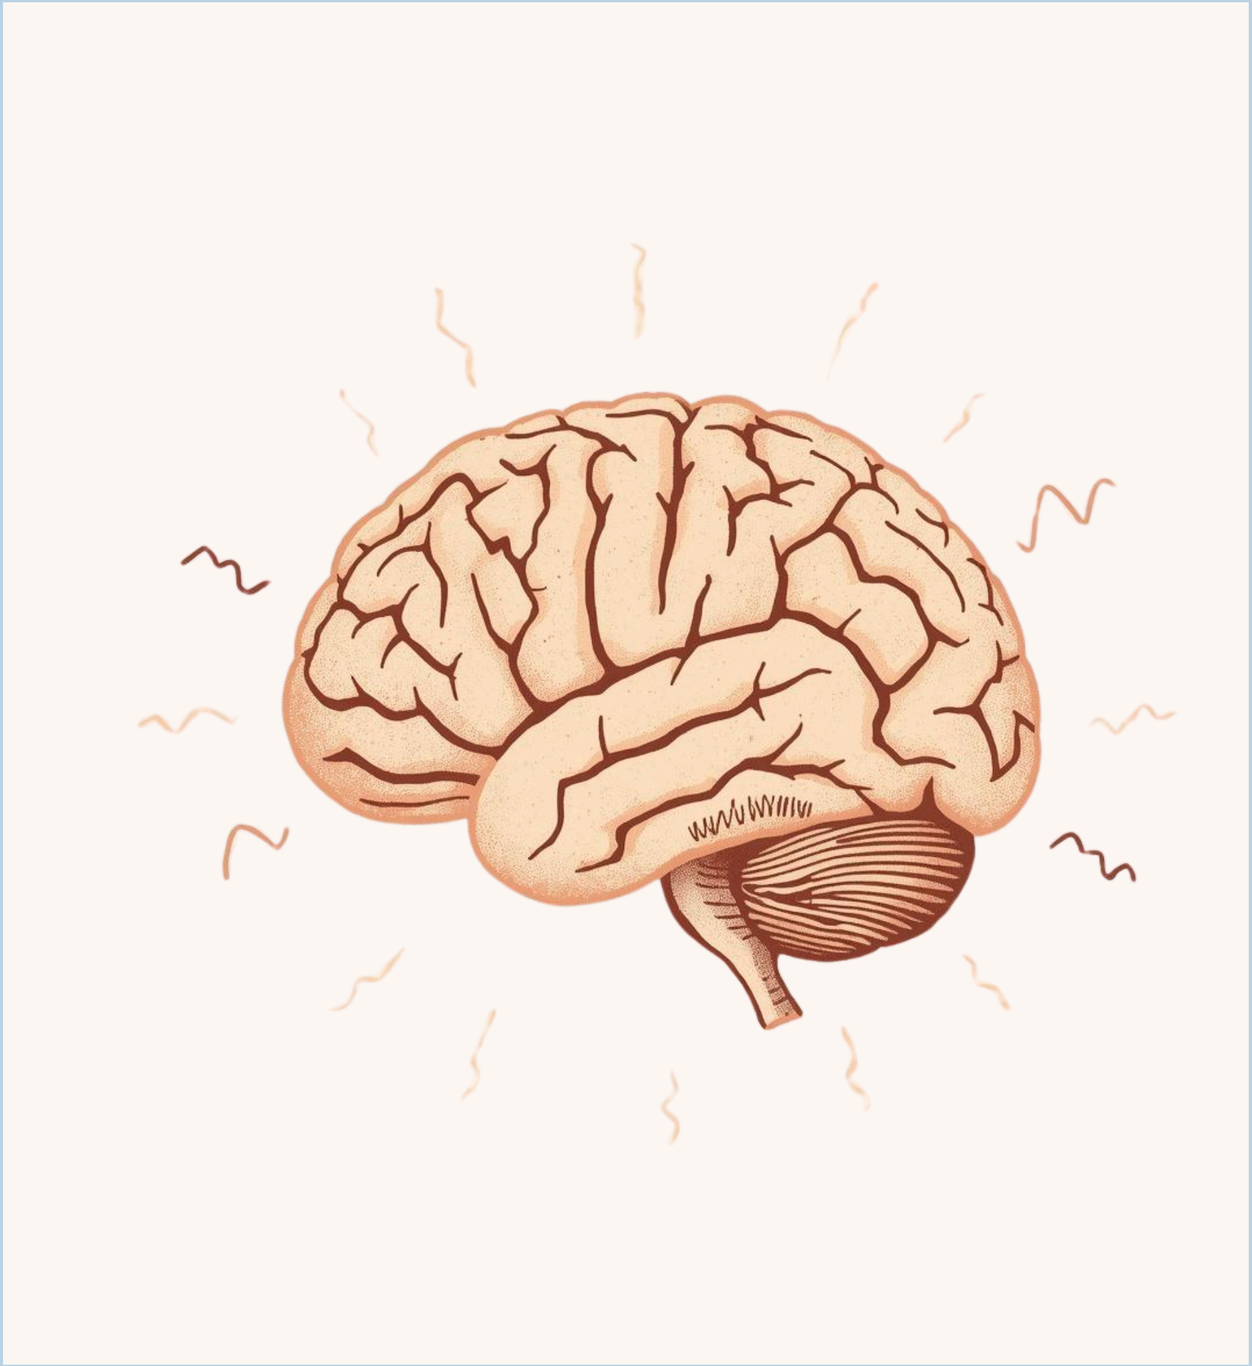
Comprendre les LSTM pour la détection de crises d'épilepsie

Présenté par Malek Azzouz et Malek Lahbib



Architecture d'une Cellule LSTM

1. Porte d'entrée

Fonction : Détermine quelles informations doivent être ajoutées à la cellule mémoire.

Entrées : L'entrée actuelle xtxt et l'état précédent \(h_{t-1_

Sortie : Génère un vecteur d'activation qui est appliqué à l'état précédent ct−1ct−1 pour actualiser la cellule mémoire.

2. Porte d'oubli

Fonction : Supprime les informations obsolètes de la cellule mémoire.

Entrées : Utilise également xtxt et \(h_{t-1_

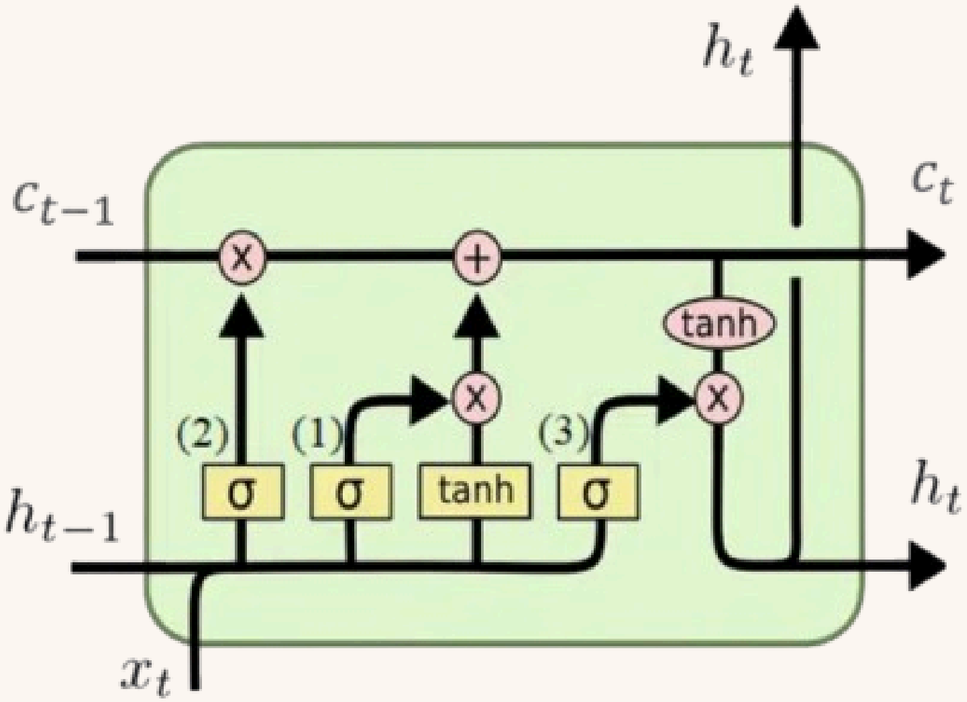
Sortie : Produit un vecteur d'activation qui détermine ce qui doit être oublié de l'état précédent ct−1ct−1, affectant ainsi l'état actuel ctct.

3. Porte de sortie

Fonction : Détermine la sortie du LSTM.

Entrées : Utilise xtxt et l'état actuel de la cellule mémoire ctct.

Sortie : Génère un vecteur d'activation qui représente la sortie du LSTM, notée ht .



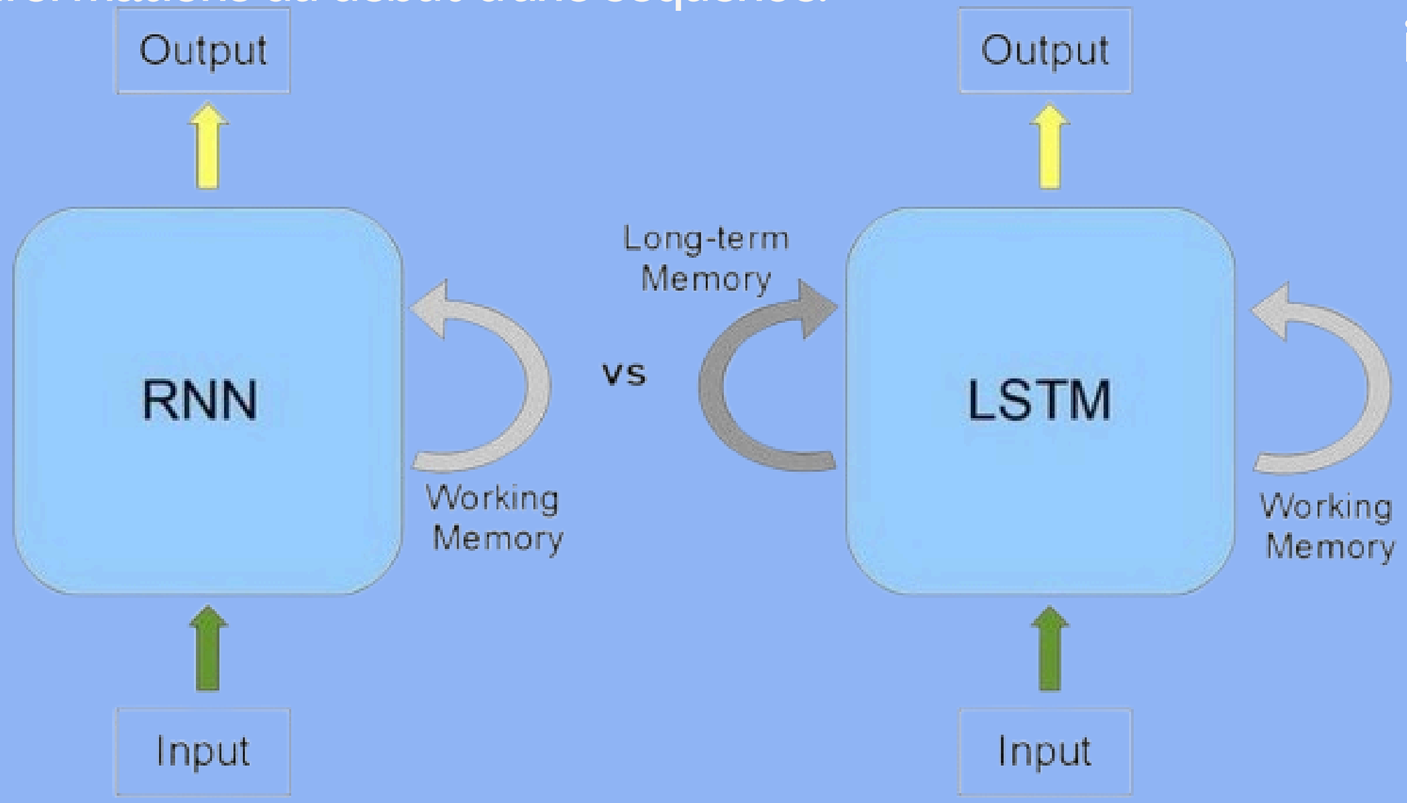
LSTM
(Long-Short Term Memory)

Schéma d'une cellule mémoire LSTM

RNN Simple vs. LSTM: Gérer le Vanishing Gradient

RNN Simple: Le Problème:

Les RNN simples ont du mal à apprendre les dépendances à long terme car les gradients diminuent (disparaissent) lors de la rétropropagation à travers de nombreux pas de temps, rendant difficile pour le réseau de se souvenir des informations du début d'une séquence.



LSTM: La Solution:

Le LSTM résout ce problème grâce à son état de cellule et ses portes, permettant au gradient de circuler plus librement et de maintenir les informations sur de longues séquences.

Scénarios d'Application Idéaux pour les LSTM

Séquences longues (texte, séries temporelles financières, signaux physiologiques)
Données avec dépendances temporelles (prédiction, reconnaissance vocale, traduction automatique)
Détection d'anomalies temporelles (surveillance industrielle, fraudes)
Génération de séquences (texte, composition musicale)

Avantages de l'approche LSTM

Le LSTM excelle dans la capture des dépendances à long terme, résiste au vanishing gradient, offre une grande flexibilité architecturale et des performances supérieures pour les tâches séquentielles complexes.

- Précision améliorée
- Adaptabilité aux signaux variés
- Détection en temps réel

LSTM: Points Forts et Faiblesses

Malgré ses atouts, le LSTM est gourmand en calcul, susceptible au surapprentissage et difficile à interpréter, nécessitant une optimisation rigoureuse des hyperparamètres.

LSTM en Action: Applications Concrètes

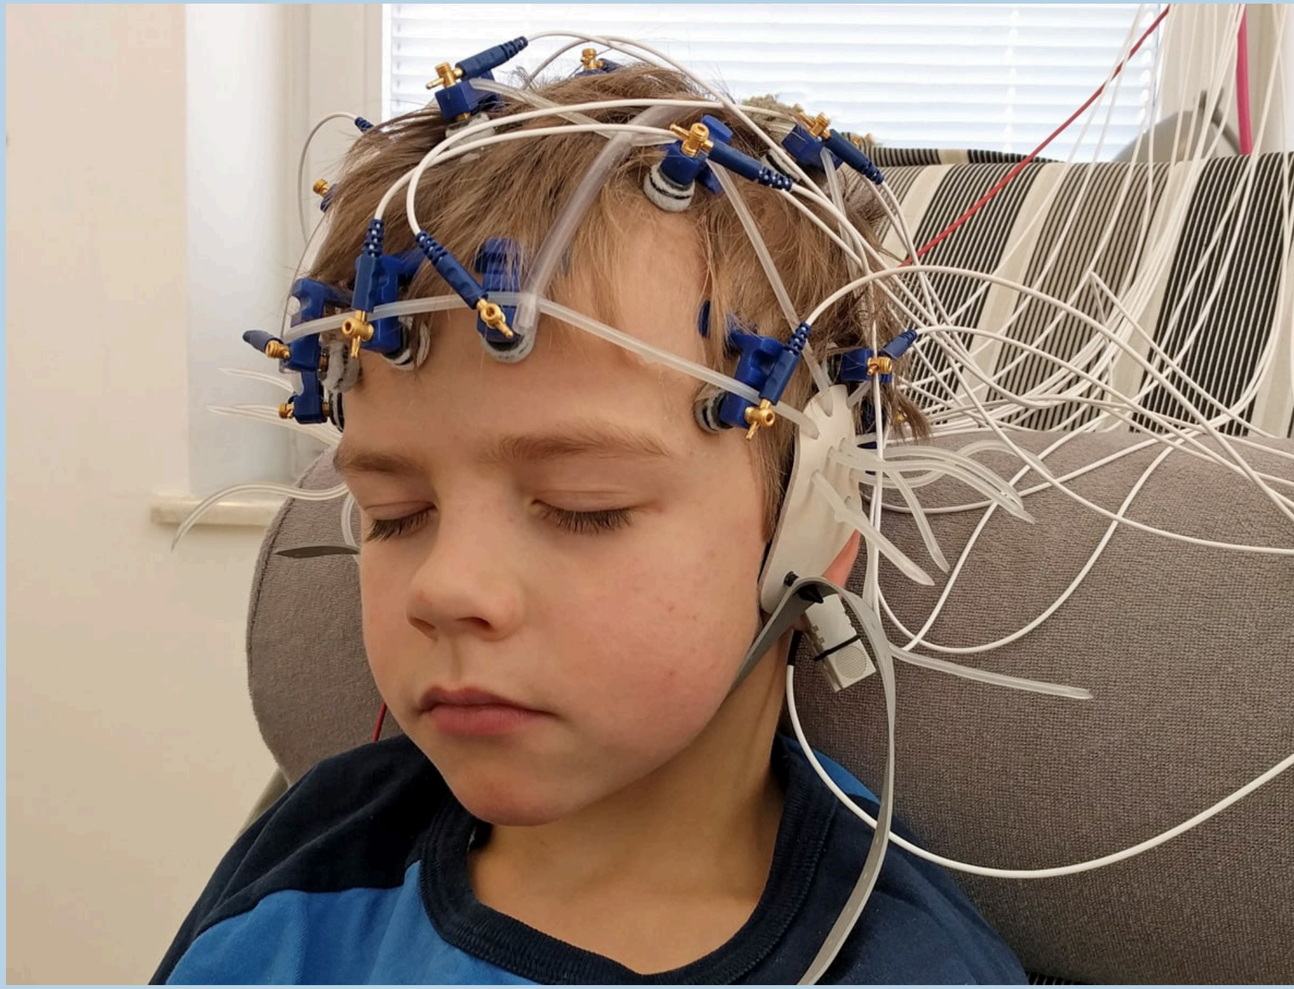
Prévision boursière (analyse financière)

Diagnostic médical (ECG, EEG)

Conduite autonome (prédiction de mouvements)

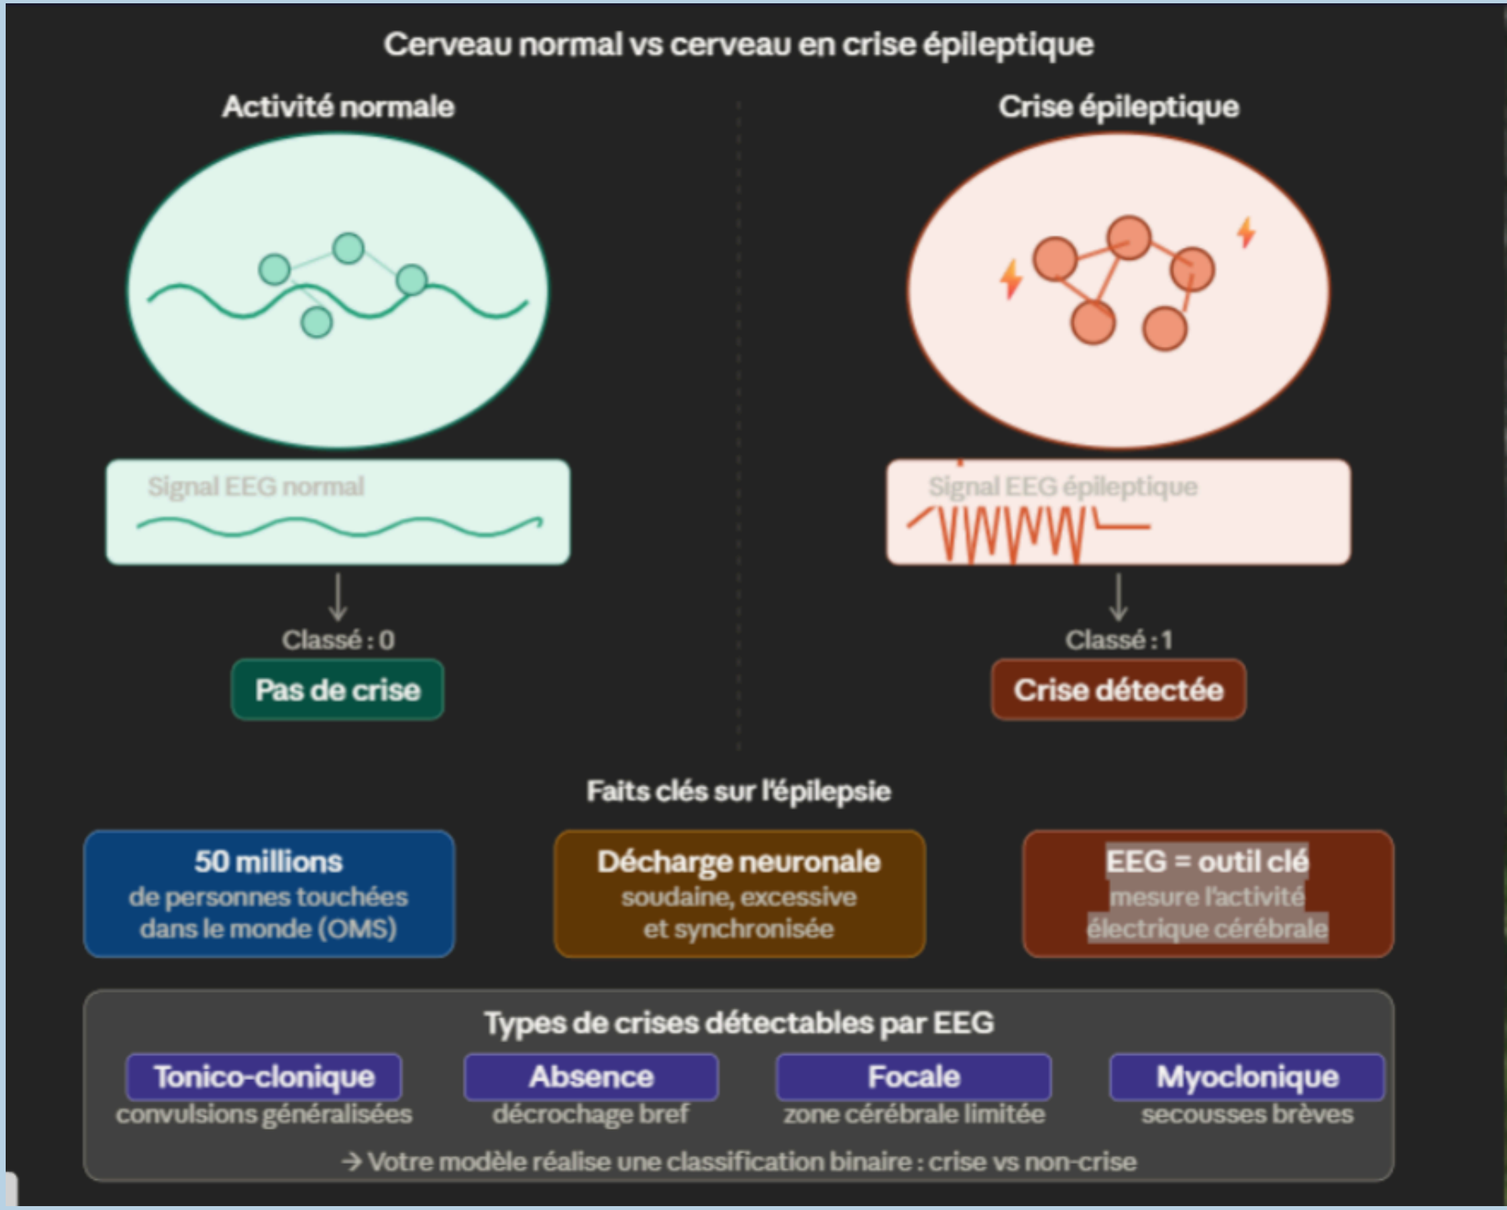
Notre Application: Détection de Crises d'Épilepsie

Nous avons utilisé le dataset 'Epileptic Seizure Recognition' de Kaggle (11 500 échantillons, 178 points EEG par seconde) pour une classification binaire. Ce dataset est idéal pour le LSTM en raison de la nature séquentielle des signaux EEG.



Ce que fait le model :

L'épilepsie est une maladie neurologique caractérisée par des décharges électriques neuronales anormales, soudaines et répétées. Pendant une crise, des millions de neurones s'activent de façon synchronisée et chaotique, ce qui produit un signal EEG très caractéristique des oscillations rapides et de grande amplitude que notre LSTM apprend à reconnaître .



- Simplicité et rapidité de développement grâce à son API de haut niveau.
- Documentation abondante et communauté large pour le support.
- Intégration complète avec l'écosystème Python de science des données.
- Flexibilité permettant un contrôle granulaire si nécessaire.

Choix de la Bibliothèque: Keras/TensorFlow

Étapes de Préprocessing pour les Données EEG:

Gestion des valeurs manquantes: Aucune valeur manquante détectée, essentiel pour les signaux continus

Normalisation (StandardScaler): Centre les données et réduit l'écart-type pour une meilleure convergence.

Création des séquences: Le dataset fournit des séquences prêtes de 178 pas de temps (1 seconde d'EEG).

Split train/validation/test (70/15/15) avec stratification pour préserver le ratio de classes.

Architecture Détaillée de Notre Modèle LSTM

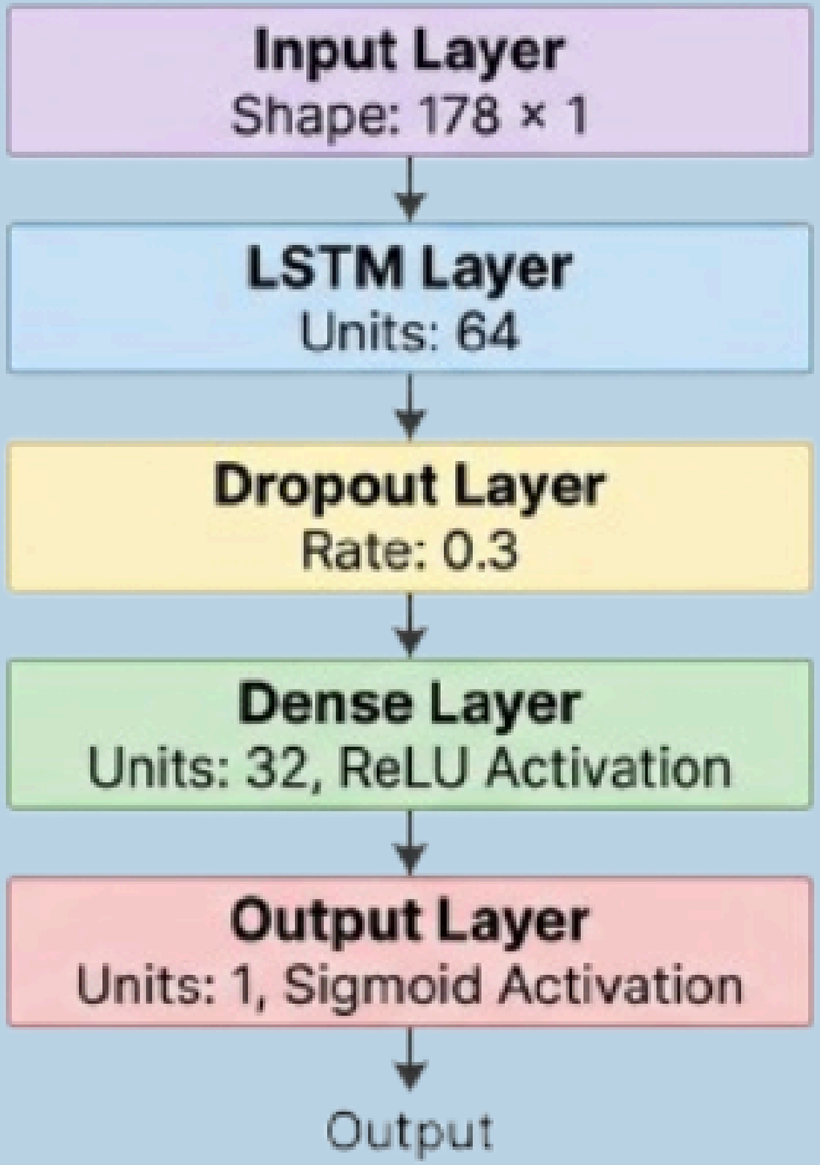
-Couche LSTM: 1 couche avec 64 unités, input_shape=(178, 1)

-Dropout: 0.3 (30%) appliqué pour réduire le surapprentissage

-Couche Dense 1: 32 neurones avec activation ReLU

-Couche Dense 2: 1 neurone avec activation Sigmoid

-Compilation: Optimiseur Adam (lr=0.001), fonction de perte binary_crossentropy, métrique accuracy



Comparaison des Performances: LSTM vs. RNN Simple

97.28%

Accuracy LSTM (92.87% RNN)

0.9942

AUC-ROC LSTM (0.9367 RNN)

0.9318

F1-Score LSTM (0.8032 RNN)

0.

93

Recall Crise LSTM (0.73 RNN)

Comparaison des Performances: LSTM vs. GRU

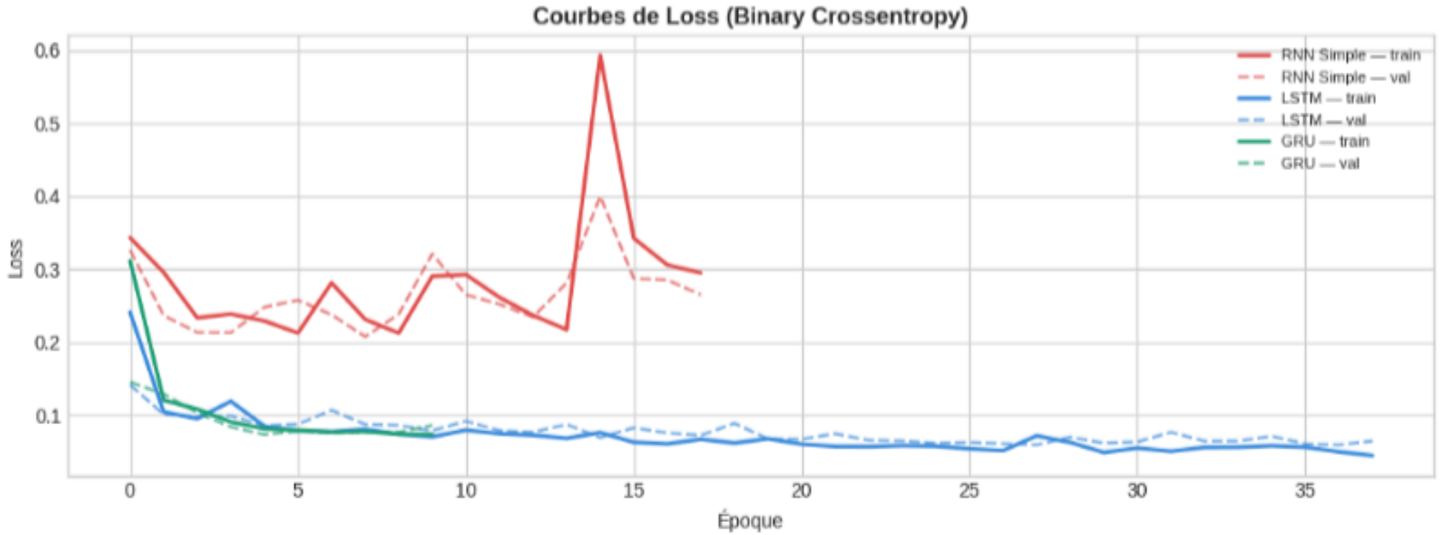
94.78%
GRU

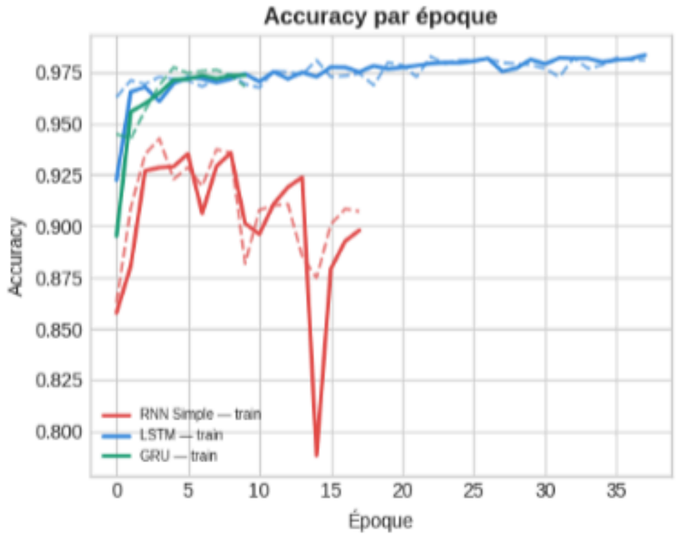
AUC-ROC
0.9814
GRU

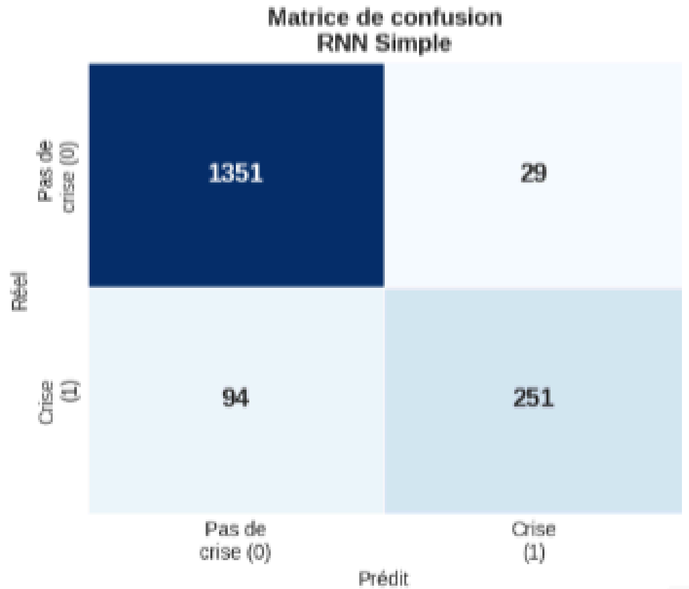
F1-Score
0.8673
GRU

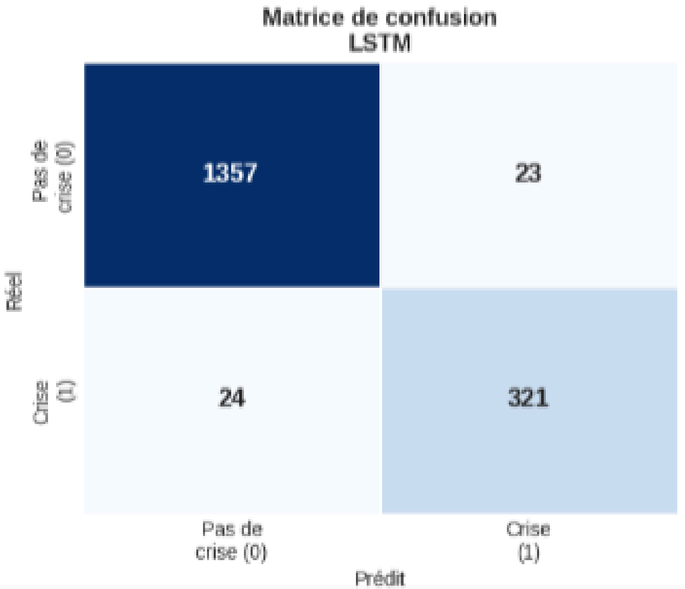
Temps d'entraînement
194.1 s GRU vs 616,4 LSTM

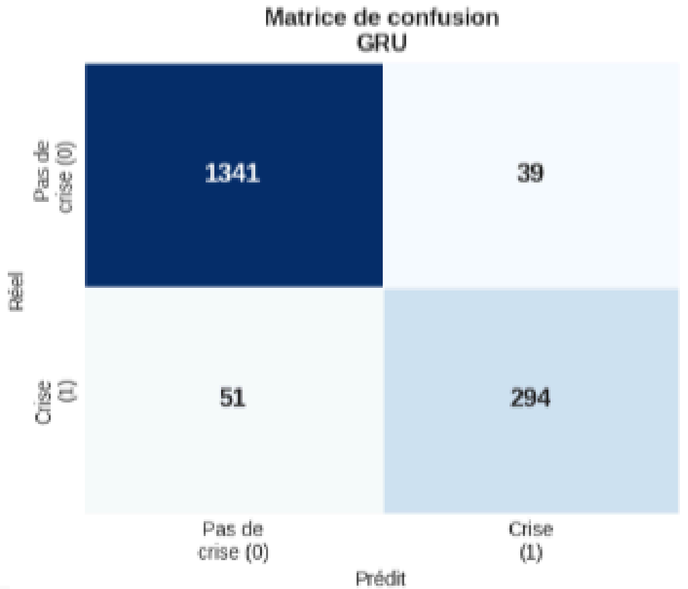
Comparaison LSTM vs RNN Simple vs GRU
Dataset : Epileptic Seizure Recognition (EEG)

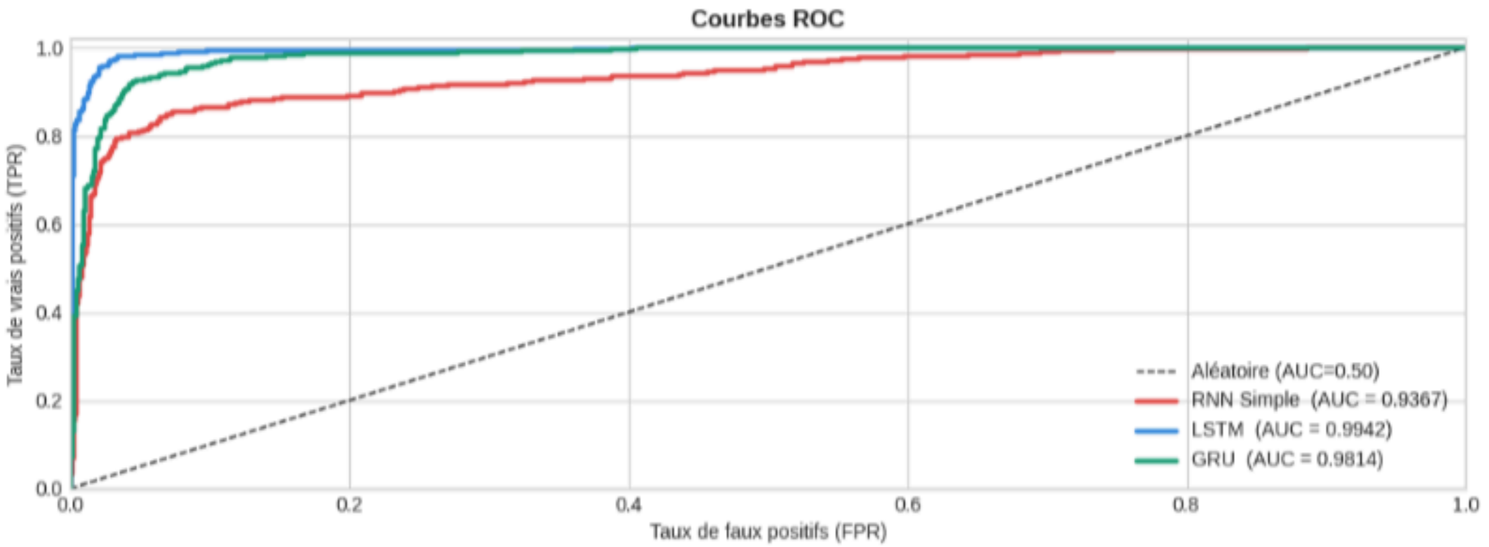












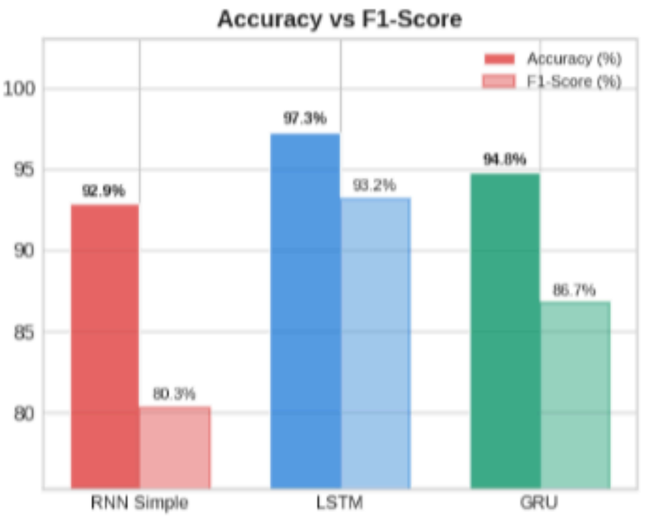


Tableau Comparatif Final — Test Set

Modèle	Accuracy	AUC-ROC	F1-Score	Nb Paramètres	Temps entraîn.	Epochs
RNN Simple	92.87%	0.9367	0.8032	6,337	108.7s	18 / 80
LSTM	97.28%	0.9942	0.9318	19,009	616.4s	38 / 80
GRU	94.78%	0.9814	0.8673	14,977	194.1s	10 / 80

Conclusion Générale et Limites Observées

Le LSTM a atteint une excellente performance (accuracy 97.28%, AUC-ROC 0.9942) pour la détection des crises d'épilepsie.

Le preprocessing et les techniques de régularisation (dropout, early stopping) ont été efficaces.

Limites: Temps d'entraînement élevé pour le LSTM, nature segmentée du dataset, absence de validation externe.

Améliorations Possibles pour le Futur du Projet:



Merci !

